

Supervised learning

customer type	# of new recipients	email length	country	email type
gold	0	2	germany	-
silver	1	4	germany	-
Bronze	5	2	Nigeria	Spam
Bronze	2	4	ruSSia	Spam
Bronze	3	4	USA	-
gold	0	1	USA	-

ללא קטגוריות
מאפיינים
מאפיינים
סוגי דיוור:

Instance נקראת

Feature נקראת

Labels נקראת

X ו X instance נקראת
 Y label מסומן

הפונקציה "מיני"

$$L = (h(x) - y)^2$$

$h(x)$ - ההיפוטזה

L - מיני


$$l(x_i, y_i, h) = (h(x_i) - y_i)^2$$

$$L_S = \frac{1}{n} \sum_i^m l(x_i, y_i, h) = \frac{1}{n} \sum_i^m (h(x_i) - y_i)^2$$

$$L_D = E_{x \sim D} [l(x_i, y_i, h)]$$

$$h(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_N x_N$$

יש 6 מיני פרכים להגדיר $Loss$, כשאלים
הגורמים לראיית מחדשים אמצוא מהיבוא
למינימם את מהותן הסדרית מהחל



$$S_d = \sum d \rightarrow \min \rightarrow (S_d)'$$

$$L_S = \frac{1}{2m} \sum_{i=1}^m (h(x_i) - y_i)^2$$

סכום

2 נק. (סכום)

אם התקנה האנזיג

מ פס'מ

$x, y, h \leftarrow$ עבור כל דגם

$$X = \begin{bmatrix} x_1^T & - \\ x_2^T & - \\ \vdots & \vdots \\ x_m^T & - \end{bmatrix}$$

פ'צ'רים

דגמים (instances)

לכן, כיוון שהמרחק מהמוצא (היפוטזה) יכול להיות
חיובי/שלילי $(h - y)$, מתייחסים לריבוע המרחק

$(h - y)^2$ כאשר h היא פונקציה של הפ'צ'רים.

הנחת ליניאריות:

$$h(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$$


↑
bias

↑
פיר 1

↑
פיר 2

↑
פיר n

בהקרה של צו ליניארי



המשוואה

$$h = \theta_0 + \theta_1 x$$

כיוון שפונקציה זו היא ליניארית (הצורה)

$$L = \frac{1}{2m} \sum (h - y)^2$$

$$h = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

$$\Rightarrow \begin{bmatrix} \theta_1^T x_1 \\ \theta_1^T x_2 \\ \vdots \end{bmatrix} = \underline{\underline{X \cdot \theta}}$$

$$\begin{bmatrix} x_{11} & x_{12} & x_{13} & \dots & x_{1n} \\ x_{21} & x_{22} & x_{23} & \dots & x_{2n} \\ \vdots & & & \ddots & \\ x_{m1} & \dots & \dots & \dots & x_{mn} \end{bmatrix} \begin{bmatrix} \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}$$

$m \times n$, $n \times 1 \rightarrow m \times 1$
 כנס וקטור הטיף \sim

$$L_S = \frac{1}{2m} \| \underline{X} \underline{\theta} - \underline{y} \|^2 = \frac{1}{2m} (\underline{X} \underline{\theta} - \underline{y})^t (\underline{X} \underline{\theta} - \underline{y})$$

$\begin{matrix} 1 \times m & m \times 1 \end{matrix}$

רצונו של $\underline{\theta}$ וקטור הטיף. חוקי דיפרנציאל

הנגזרת - לא נכון, יש כמה חוקי דיפרנציאל...

$$\frac{\partial}{\partial \underline{\theta}} \left(\frac{1}{2m} (\underline{X} \underline{\theta} - \underline{y})^t (\underline{X} \underline{\theta} - \underline{y}) \right) =$$

$$\frac{\partial}{\partial \underline{\theta}} \left(\frac{1}{2m} \left[(\underline{\theta}^t \underline{X}^t - \underline{y}^t) (\underline{X} \underline{\theta} - \underline{y}) \right] \right) = 0$$

$\begin{matrix} 1 \times n & n \times m & 1 \times m & m \times n & m \times 1 \end{matrix}$

$$\rightarrow \underline{\theta}^t \underline{X}^t \underline{X} \underline{\theta} - \underline{\theta}^t \underline{X}^t \underline{y} - \underline{y}^t \underline{X} \underline{\theta} + \underline{y}^t \underline{y} = 0$$

$\begin{matrix} 1 \times n & n \times m & m \times n & m \times 1 & 1 \times n & n \times m & 1 \times m & m \times n & m \times 1 \end{matrix}$

$$\rightarrow \frac{\partial}{\partial \underline{\theta}} = \begin{matrix} 1 \times 1 & m \times 1 & 1 \times 1 \end{matrix}$$

$$2 \underline{X}^t \underline{X} \underline{\theta} - \underline{X}^t \underline{y} - \underline{X}^t \underline{y} + 0 = 0$$

$$2 \underline{X}^t \underline{X} \underline{\theta} = 2 \underline{X}^t \underline{y}$$

$$\underline{\theta} = \left(\underbrace{\underline{X}^T \underline{X}} \right)^{-1} \underline{X}^T \underline{y}$$

pinv \rightarrow never
inv e. zur 1. \rightarrow

<https://youtu.be/FCWrduAxf-Q>

Common identities:

$$\frac{\partial(u(\mathbf{x}) + v(\mathbf{x}))}{\partial \mathbf{x}} = \frac{\partial u(\mathbf{x})}{\partial \mathbf{x}} + \frac{\partial v(\mathbf{x})}{\partial \mathbf{x}}$$

$$\frac{\partial \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}^T$$

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \mathbf{a}$$

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}^T) \mathbf{x}$$

$$\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = 2 \mathbf{A} \mathbf{x} \text{ if } \mathbf{A} \text{ is symmetric}$$

$$\frac{\partial |\mathbf{X}|}{\partial \mathbf{X}} = |\mathbf{X}| (\mathbf{X}^{-1})^T$$

$$\frac{\partial \ln |\mathbf{X}|}{\partial \mathbf{X}} = (\mathbf{X}^{-1})^T$$